

1.2 Screenshot conexión a la máquina virtual.

```
Install the latest PowerShell for new features and improvements! https://aka.ms/PSWindows

PS C:\Users\nilara> ssh -i "C:\Users\nilara\Downloads\taller_3.pem" ubuntu@18.213.1.0
Welcome to Ubuntu 24.04.4 LTS (GNU/Linux 6.17.0-1017-aws x86_64)

 * Documentation:  https://help.ubuntu.com
 * Management:    https://landscape.canonical.com
 * Support:       https://ubuntu.com/pro

System information as of Sun Aug  9 20:12:28 UTC 2026

System load:  0.0           Temperature:   -273.1 C
Usage of /:   37.9% of 8.65GB Processes:      113
Memory usage: 36%          Users logged in: 0
Swap usage:   0%           IPv4 address for ens5: 172.31.25.214

Expanded Security Maintenance for Applications is not enabled.

81 updates can be applied immediately.
69 of these updates are standard security updates.
To see these additional updates run: apt list --upgradable

3 additional security updates can be applied with ESM Apps.
Learn more about enabling ESM Apps service at https://ubuntu.com/esm

*** System restart required ***
ubuntu@ip-172-31-25-214:~$ |
```

Se lanzó una instancia Ubuntu Server 24.04 LTS (AMI ami-0a0e5d9c7acc336f1), tipo t3.micro, 10 GB de almacenamiento, con acceso SSH por el puerto 22. La conexión se realizó con el comando:

```
ssh -i taller_3.pem ubuntu@18.213.1.0
```

2.7 Explorar los archivos data/data.csv e incluir pantallazos en el reporte.

```
ubuntu@ip-172-31-25-214:~/dvc-proj$ ls -la data/
total 20
drwxrwxr-x 2 ubuntu ubuntu 4096 Aug  9 19:52 .
drwxrwxr-x 5 ubuntu ubuntu 4096 Aug  9 19:52 ..
-rw-rw-r-- 1 ubuntu ubuntu  10 Aug  9 19:52 .gitignore
-rw-rw-r-- 1 ubuntu ubuntu 3858 Aug  9 19:52 data.csv
-rw-rw-r-- 1 ubuntu ubuntu  88 Aug  9 19:52 data.csv.dvc


ubuntu@ip-172-31-25-214:~/dvc-proj$ cat data/.gitignore
/data.csv

ubuntu@ip-172-31-25-214:~/dvc-proj$ cat data/data.csv.dvc
outs:
- md5: 013d0da08d6506664ce640459139176b
  size: 3858
  hash: md5
  path: data.csv
```

Tras ejecutar `dvc add data/data.csv`, DVC creó automáticamente los archivos de seguimiento.

2.9 Incluir en el reporte el link del repositorio y un screenshot de su repositorio con el archivo `.csv.dvc`.

https://github.com/nlarav-uniandes/taller3_dvc



4.9 Incluir en el reporte un screenshot del contenido del archivo `.dvc/config`, donde se evidencien los dos remotes (local y S3).

```
ubuntu@ip-172-31-25-214:~/dvc-proj$ cat .dvc/config
[core]
    remote = aws-remote
[remote "fuentelocal"]
    url = /tmp/dvcstore
[remote "aws-remote"]
    url = s3://nlarav-dvcstore
```

Se configuraron dos fuentes remotas de DVC: `fuentelocal` apuntando a `/tmp/dvcstore` y `aws-remote` apuntando al bucket S3 `nlarav-dvcstore`. El remote activo por defecto es `aws-remote`.

5.3 Incluir en su reporte un screenshot del identificador md5 del archivo `.csv`. e incluir un screenshot que evidencie que hay 2 objetos dentro de la carpeta `files/md5/` en su bucket de S3 (los identificadores de las versiones creadas).

```

ubuntu@ip-172-31-25-214:~/dvc-proj$ cat data/data.csv.dvc
outs:
- md5: 1e0306f8f8af775862f5e5dafab5bc6f
  size: 7716
  hash: md5
  path: data.csv

ubuntu@ip-172-31-25-214:~/dvc-proj$ aws s3 ls s3://nlarav-dvcstore/files/md5/ --recursive
2026-08-09 20:04:26      3858 files/md5/01/3d0da08d6506664ce640459139176b
2026-08-09 20:06:05      7716 files/md5/1e/0306f8f8af775862f5e5dafab5bc6f

```

Se simuló la creación de nuevos datos duplicando el archivo original (cat /tmp/data.csv >> data/data.csv, de 151 a 302 líneas). Tras ejecutar dvc add y dvc push, el archivo data.csv.dvc actualizado muestra el nuevo hash md5

El bucket S3 nlarav-dvcstore contiene exactamente 2 objetos en files/md5/, correspondientes a las dos versiones del dataset (151 filas y 302 filas respectivamente).

5.5 Incluir en su reporte un screenshot del repositorio clonado correctamente en otra carpeta.

```

ubuntu@ip-172-31-25-214:~$ git clone https://github.com/nlarav-uniandes/taller3_dvc.git taller3_clone
Cloning into 'taller3_clone'...

ubuntu@ip-172-31-25-214:~$ cd taller3_clone

ubuntu@ip-172-31-25-214:~/taller3_clone$ ls -la data/
total 16
drwxrwxr-x 2 ubuntu ubuntu 4096 Aug  9 20:07 .
drwxrwxr-x 5 ubuntu ubuntu 4096 Aug  9 20:07 ..
-rw-rw-r-- 1 ubuntu ubuntu  10 Aug  9 20:07 .gitignore
-rw-rw-r-- 1 ubuntu ubuntu  88 Aug  9 20:07 data.csv.dvc
    (data.csv no presente - gestionado por DVC)

ubuntu@ip-172-31-25-214:~/taller3_clone$ dvc pull
A      data/data.csv
1 file fetched and 1 file added

ubuntu@ip-172-31-25-214:~/taller3_clone$ ls -la data/
total 24
drwxrwxr-x 2 ubuntu ubuntu 4096 Aug  9 20:07 .
drwxrwxr-x 5 ubuntu ubuntu 4096 Aug  9 20:07 ..
-rw-rw-r-- 1 ubuntu ubuntu  10 Aug  9 20:07 .gitignore
-rw-rw-r-- 1 ubuntu ubuntu 7716 Aug  9 20:07 data.csv
-rw-rw-r-- 1 ubuntu ubuntu  88 Aug  9 20:07 data.csv.dvc

```

Se clonó el repositorio GitHub en una nueva carpeta taller3_clone. Tras el clone, la subcarpeta data/ solo contenía el archivo de seguimiento (data.csv.dvc), sin el CSV real. Se ejecutó dvc pull para obtener los datos desde S3.

6 Incluir en su reporte un screenshot realizando una exploración de los comandos git checkouty dvc checkout.

```
ubuntu@ip-172-31-25-214:~/dvc-proj$ git log --oneline
a305c6b Dataset actualizado
025a941 Adicionar S3 como remote
46a7e31 Primera version de los datos
f21cdd3 Inicializacion de DVC

ubuntu@ip-172-31-25-214:~/dvc-proj$ git checkout -b nueva-rama
Switched to a new branch 'nueva-rama'

ubuntu@ip-172-31-25-214:~/dvc-proj$ dvc checkout

ubuntu@ip-172-31-25-214:~/dvc-proj$ git branch
  main
* nueva-rama

ubuntu@ip-172-31-25-214:~/dvc-proj$ ls -la data/
total 24
drwxrwxr-x 2 ubuntu ubuntu 4096 Aug  9 20:06 .
drwxrwxr-x 5 ubuntu ubuntu 4096 Aug  9 19:52 ..
-rw-rw-r-- 1 ubuntu ubuntu  10 Aug  9 19:52 .gitignore
-rw-rw-r-- 1 ubuntu ubuntu 7716 Aug  9 20:06 data.csv
-rw-rw-r-- 1 ubuntu ubuntu  88 Aug  9 20:06 data.csv.dvc
```

Se creó la rama nueva-rama y se ejecutó dvc checkout para garantizar que los datos rastreados por DVC corresponden al estado de esa rama. dvc checkout sincroniza el workspace con los archivos .dvc del commit activo.

La nueva rama nueva-rama hereda el estado más reciente de main (dataset duplicado). El comando dvc checkout asegura que el archivo de datos en el workspace corresponde exactamente al hash registrado en data.csv.dvc para ese commit.